

Inhalte mit der Gemini API in Vertex AI generieren

Mit `generateContent` oder `streamGenerateContent` Inhalte mit Gemini generieren

Die Gemini-Modellfamilie umfasst Modelle, die mit multimodalen Prompt-Anfragen arbeiten. Der Begriff „multimodal“ bedeutet, dass Sie in einem Prompt mehr als eine Modalität oder Art von Eingabe verwenden können. Modelle, die nicht multimodal sind, akzeptieren nur Prompts mit Text. Modalitäten können Text, Audio, Video und mehr umfassen.

Google Cloud -Konto erstellen

Wenn Sie die Gemini API in Vertex AI verwenden möchten, [erstellen Sie ein Google Cloud Konto](#)

(<https://console.cloud.google.com/freetrial?redirectPath=%2Fmarketplace%2Fproduct%2Fgoogle%2Fcloudai.companion.googleapis.com&hl=de>).

Nachdem Sie Ihr Konto erstellt haben, können Sie in diesem Dokument den [Anfragetext](#) (`#request`), die [Modellparameter](#) (`#parameters`), den [Antworttext](#) (`#response`) und einige Beispiele [anfragen](#) (`#sample-requests`) des Gemini-Modells überprüfen.

Wenn Sie bereit sind, lesen Sie in der [Kurzanleitung zur Gemini API in Vertex AI](#)

(<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/start/quickstarts/quickstart-multimodal?hl=de>) nach, wie Sie eine Anfrage an die Gemini API in Vertex AI mit einem SDK für Programmiersprachen oder der REST API senden.

Unterstützte Modelle

Alle Gemini-Modelle unterstützen die Erstellung von Inhalten.

Hinweis :Wenn Sie einer Anfrage viele Bilder hinzufügen, erhöht sich die Antwortlatenz.

Parameterliste

Einzelheiten zur Implementierung finden Sie in den [Beispielen](#) (`#sample-requests`).

Anfragetext

```
{
  "cachedContent": string,
  "contents": [
    {
      "role": string,
      "parts": [
        {
          // Union field data can be only one of the following:
          "text": string,
          "inlineData": {
            "mimeType": string,
            "data": string
          },
          "fileData": {
            "mimeType": string,
            "fileUri": string
          },
        },
        // End of list of possible types for union field data.

        "videoMetadata": {
          "startOffset": {
            "seconds": integer,
```

```
        "nanos": integer
      },
      "endOffset": {
        "seconds": integer,
        "nanos": integer
      },
      "fps": double
    }
  ]
}
],
"systemInstruction": {
  "role": string,
  "parts": [
    {
      "text": string
    }
  ]
},
"tools": [
  {
    "functionDeclarations": [
      {
        "name": string,
        "description": string,
        "parameters": {
          object (Ope(https://spec.openapis.org/oas/v3.0.3#schema)nAPI_Object_Schema(https://spec.openapis.org/oas/v3.0.3#schema))
        }
      }
    ]
  }
],
"safetySettings": [
  {
    "category": enum (HarmCategory),
    "threshold": enum (HarmBlockThreshold)
  }
],
"generationConfig": {
  "temperature": number,
  "topP": number,
  "topK": number,
  "candidateCount": integer,
  "maxOutputTokens": integer,
  "presencePenalty": float,
  "frequencyPenalty": float,
  "stopSequences": [
    string
  ],
  "responseMimeType": string,
  "responseSchema": schema(https://docs.cloud.google.com/vertex-ai/docs/reference/rest/v1/projects.locations.cachedContents?hl=de#Schema),
  "seed": integer,
  "responseLogprobs": boolean,
  "logprobs": integer,
  "audioTimestamp": boolean,
  "thinkingConfig": {
    "thinkingBudget": integer
  }
},
"labels": {
  string: string
}
}
```

Der Anfragetext enthält Daten mit den folgenden Parametern:

Parameter	
cachedContent	Optional: string Der Name des im Cache gespeicherten Inhalts, der als Kontext für die Vorhersage verwendet wird. Format: projects/{project}/locations/{location}/cachedContents/{cachedContent}

contents	Erforderlich: Content Der Inhalt der aktuellen Unterhaltung mit dem Modell. Bei Einzelabfragen ist dies eine einzelne Instanz. Bei Mehrfachabfragen ist dies ein wiederkehrendes Feld, das den Unterhaltungsverlauf und die letzte Anfrage enthält.
systemInstruction	Optional: Content Verfügbar für gemini-2.0-flash und gemini-2.0-flash-lite. Anleitung für das Modell, um es zu einer besseren Leistung zu steuern. Beispiel: „Antworten Sie so kurz wie möglich“ oder „Verwenden Sie in Ihrer Antwort keine technischen Begriffe“. Die text-Strings werden auf das Tokenlimit angerechnet. Das Feld role von systemInstruction wird ignoriert und wirkt sich nicht auf die Leistung des Modells aus. ★ Hinweis: In parts sollte nur text verwendet werden. Der Inhalt jedes part sollte in einem separaten Absatz stehen.
tools	Optional. Ein Code, der es dem System ermöglicht, mit externen Systemen zu interagieren, um eine Aktion oder eine Reihe von Aktionen außerhalb des Wissens und Umfangs des Modells auszuführen. Weitere Informationen (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de)
toolConfig	Optional. Weitere Informationen (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de)
safetySettings	Optional: SafetySetting Einstellungen pro Anfrage zum Blockieren unsicherer Inhalte. Erzwungen am GenerateContentResponse.candidates
generationConfig	Optional: GenerationConfig Einstellungen für die Generierungskonfiguration.
labels	Optional: string Metadaten, die Sie dem API-Aufruf im Format von Schlüssel/Wert-Paaren hinzufügen können.

contents

Der strukturierte Basisdatentyp, der mehrteilige Inhalte einer Nachricht enthält.

Diese Klasse besteht aus zwei Hauptattributen: **role** und **parts**. Das Attribut **role** bezeichnet die Person, die den Inhalt erzeugt, während das Attribut **parts** mehrere Elemente enthält, die jeweils ein Datensegment innerhalb einer Nachricht darstellen.

Parameter

role	string Die Identität der Entität, die die Nachricht erstellt. Folgende Werte werden unterstützt: user: Gibt an, dass die Nachricht von einer realen Person gesendet wurde, in der Regel eine von Nutzern erstellte Nachricht. model: Gibt an, dass die Nachricht vom Modell generiert wird. Der Wert model wird verwendet, um Nachrichten aus dem Modell in die Unterhaltung einzufügen, die Unterhaltungen über mehrere Themen führen.
parts	Part Eine Liste geordneter Teile einer einzelnen Nachricht. Verschiedene Teile haben möglicherweise unterschiedliche IANA-MIME-Typen (https://www.iana.org/assignments/media-types/media-types.xml). Informationen zu den Limits für die Eingaben, z. B. die maximale Anzahl von Tokens oder die Anzahl der Bilder, finden Sie in den Modellspezifikationen auf der Seite Google-Modelle (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/models?hl=de). Informationen zum Berechnen der Anzahl der Tokens in Ihrer Anfrage finden Sie unter Tokenanzahl abrufen (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/get-token-count?hl=de).

parts

Ein Datentyp mit Medien, die Teil einer mehrteiligen Content-Nachricht sind.

Parameter	
text	Optional: string Ein Text-Prompt oder ein Code-Snippet.
inlineData	Optional: Blob Inline-Daten in Rohbyte. Für gemini-2.0-flash-lite und gemini-2.0-flash können Sie mit inlineData bis zu 3.000 Bilder angeben.
fileData	Optional: fileData In einer Datei gespeicherte Daten.
functionCall	Optional: FunctionCall. Es enthält einen String, der das Feld FunctionDeclaration.name darstellt, und ein strukturiertes JSON-Objekt mit allen Parametern für den vom Modell vorhergesagten Funktionsaufruf. <u>Weitere Informationen</u> (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de)
functionResponse	Optional: FunctionResponse. Die Ergebnisausgabe eines FunctionCall, das einen String enthält, der das Feld FunctionDeclaration.name darstellt, und ein strukturiertes JSON-Objekt, das die Ausgabe des Funktionsaufrufs enthält. Sie wird als Kontext für das Modell verwendet. <u>Weitere Informationen</u> (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de)
videoMetadata	Optional: VideoMetadata Bei Videoeingabe der Start- und Endversatz des Videos im <u>Duration</u> (https://protobuf.dev/reference/protobuf/google.protobuf/#duration)-Format und die Framerate des Videos . Wenn Sie beispielsweise einen 10-Sekunden-Clip ab 1:00 Uhr mit einer Bildrate von 10 Bildern pro Sekunde angeben möchten, legen Sie Folgendes fest: • "startOffset": { "seconds": 60 } • "endOffset": { "seconds": 70 } • "fps": 10.0 Die Metadaten sollten nur angegeben werden, wenn die Videodaten in inlineData oder fileData präsentiert werden.

blob

Inhalts-Blob Wenn möglich, senden Sie dies als Text und nicht als Rohbyte.

Parameter	
contentType	string
data	Der Medientyp der Datei, die in den Feldern <code>data</code> oder <code>fileUri</code> angegeben wurde. Unter anderem sind folgende Werte zulässig: • application/pdf • audio/mpeg • audio/mp3 • audio/wav • image/png • image/jpeg • image/webp • text/plain • video/mov • video/mpeg • video/mp4
fileUri	string

- `video/mpg`
- `video/avi`
- `video/wmv`
- `video/mpegps`
- `video/flv`

Bei `gemini-2.0-flash-lite` und `gemini-2.0-flash` beträgt die maximale Länge einer Audiodatei 8, 4 Stunden und die maximale Länge einer Videodatei (ohne Audio) 1 Stunde. Weitere Informationen finden Sie unter [Audioanforderungen](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/audio-understanding?hl=de#audio-requirements) (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/audio-understanding?hl=de#audio-requirements>) und [Videoanforderungen](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/video-understanding?hl=de#video-requirements) (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/video-understanding?hl=de#video-requirements>) für Gemini.

Textdateien müssen UTF-8-codiert sein. Der Inhalt der Textdatei wird auf das Tokenlimit angerechnet.

Bei der Bildauflösung gibt es keine Begrenzung.

<code>data</code>	<code>bytes</code> Die base64-Codierung (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/image/base64-encode?hl=de) des Bildes oder Videos, das inline in den Prompt aufgenommen werden soll. Wenn Sie Medien inline einschließen, müssen Sie auch den Medientyp (<code>mimeType</code>) der Daten angeben. Größenbeschränkung: 20 MB.
-------------------	---

FileData

URI- oder Web-URL-Daten.

Parameter	
<code>mimeType</code>	<code>string</code> IANA-MIME-Typ (https://www.iana.org/assignments/media-types/media-types.xml) der Daten.
<code>fileUri</code>	<code>string</code> Der URI oder die URL der Datei, die in den Prompt aufgenommen werden soll. Zulässige Werte: • Cloud Storage-Bucket-URI:Das Objekt muss entweder öffentlich lesbar sein oder sich im selben Google Cloud Projekt befinden, von dem die Anfrage gesendet wird. Für <code>gemini-2.0-flash</code> und <code>gemini-2.0-flash-lite</code> beträgt die Größenbeschränkung 2 GB. • HTTP-URL: Die Datei-URL muss öffentlich lesbar sein. Sie können eine Videodatei, eine Audiodatei und bis zu 10 Bilddateien pro Anfrage angeben. Audio- und Videodateien sowie Dokumente dürfen nicht größer als 15 MB sein. • YouTube-Video-URL:Das YouTube-Video muss entweder dem Konto gehören, mit dem Sie sich in der Google Cloud Console angemeldet haben, oder öffentlich sein. Pro Anfrage wird nur eine YouTube-Video-URL unterstützt. Wenn Sie einen <code>fileURI</code> angeben, müssen Sie auch den Medientyp (<code>mimeType</code>) der Datei angeben. Wenn VPC Service Controls aktiviert ist, wird die Angabe einer Media-Datei-URL für <code>fileURI</code> nicht unterstützt.

functionCall

Ein vorhergesagter `functionCall`, der vom Modell zurückgegeben wird und einen String enthält, der `functionDeclaration.name` und ein strukturiertes JSON-Objekt enthält, das die Parameter und ihre Werte enthält.

Parameter	
<code>name</code>	<code>string</code> Der Name der aufzurufenden Funktion.
<code>args</code>	<code>Struct</code> Die Funktionsparameter und -werte im JSON-Objektformat. Weitere Informationen zu Parametern finden Sie unter Funktionsaufrufe (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de).

functionResponse

Die resultierende Ausgabe von einem FunctionCall, das einen String mit der FunctionDeclaration.name enthält. Enthält auch ein strukturiertes JSON-Objekt mit der Ausgabe der Funktion, das als Kontext für das Modell verwendet wird. Dieser sollte das Ergebnis einer FunctionCall enthalten, die auf der Grundlage der Modellvorhersage erstellt wurde.

Parameter	
name	string Der Name der aufzurufenden Funktion.
response	Struct Die Funktionsantwort im JSON-Objektformat.

videoMetadata

Metadaten, die den eingegebenen Videocontent beschreiben.

Parameter	
startOffset	Optional: google.protobuf.Duration Startversatz des Videos.
endOffset	Optional: google.protobuf.Duration Endversatz des Videos.
fps	Optional: double Die Framerate des Videos, das an das Modell gesendet wurde. Wenn keine Angabe gemacht wird, ist der Standardwert 1.0. Der akzeptierte Mindestwert liegt bei 0.0, aber nicht darunter. Der Höchstwert beträgt 24.0.

safetySetting

Sicherheitseinstellungen.

Parameter	
category	Optional: HarmCategory Die Sicherheitskategorie, für die ein Schwellenwert konfiguriert wird. Unter anderem sind folgende Werte zulässig: Zum Maximieren von Sicherheitskategorien klicken - HARM_CATEGORY_SEXUALLY_EXPLICIT - HARM_CATEGORY_HATE_SPEECH - HARM_CATEGORY_HARASSMENT - HARM_CATEGORY_DANGEROUS_CONTENT
threshold	Optional: HarmBlockThreshold Der Schwellenwert für das Blockieren von Antworten, die basierend auf der Wahrscheinlichkeit zur angegebenen Sicherheitskategorie gehören könnten. - OFF - BLOCK_NONE - BLOCK_LOW_AND_ABOVE - BLOCK_MEDIUM_AND_ABOVE - BLOCK_ONLY_HIGH

method	Optional: HarmBlockMethod
	Geben Sie an, ob der Schwellenwert für den Wahrscheinlichkeits- oder den Schweregradwert verwendet wird. Wenn nicht angegeben, wird der Schwellenwert für den Wahrscheinlichkeitswert verwendet.

harmCategory

Schadenskategorien, die Inhalte blockieren

Parameter	
HARM_CATEGORY_UNSPECIFIED	Die Schadenskategorie ist nicht angegeben.
HARM_CATEGORY_HATE_SPEECH	Die Schadenskategorie ist Hassrede.
HARM_CATEGORY_DANGEROUS_CONTENT	Die Schadenskategorie ist gefährlicher Inhalt.
HARM_CATEGORY_HARASSMENT	Die Schadenskategorie ist Belästigung.
HARM_CATEGORY_SEXUALLY_EXPLICIT	Die Schadenskategorie umfasst sexuell explizite Inhalte.

harmBlockThreshold

Wahrscheinlichkeitsschwellenwerte, die zum Blockieren einer Antwort verwendet werden.

Parameter	
HARM_BLOCK_THRESHOLD_UNSPECIFIED	Unbekannter Schwellenwert für Schadenssperre.
BLOCK_LOW_AND_ABOVE	Niedrigeren Schwellenwert und höher blockieren (d. h. mehr blockieren).
BLOCK_MEDIUM_AND_ABOVE	Mittleren Grenzwert und höher blockieren.
BLOCK_ONLY_HIGH	Nur einen hohen Schwellenwert blockieren (d. h. weniger blockieren).
BLOCK_NONE	Keine blockieren.
OFF	Sicherheit wird deaktiviert, wenn alle Kategorien deaktiviert sind

harmBlockMethod

Ein Wahrscheinlichkeitsschwellenwert, der eine Antwort basierend auf einer Kombination aus Wahrscheinlichkeit und Schweregrad blockiert.

Parameter	
HARM_BLOCK_METHOD_UNSPECIFIED	Die Methode der Schadenssperre ist nicht angegeben.
SEVERITY	Die Methode der Schadenssperre verwendet Punktzahlen sowohl für die Wahrscheinlichkeit als auch den Schweregrad.
PROBABILITY	Die Methode der Schadenssperre verwendet den Wahrscheinlichkeitswert.

generationConfig

Konfigurationseinstellungen, die beim Generieren des Prompts verwendet werden.

Parameter	
temperature	Optional: float Die Temperatur wird für die Probenahme während der Antwortgenerierung verwendet. Dies passiert, wenn topP und topK angewendet werden. Die Temperatur bestimmt den Grad der Zufälligkeit bei der Tokenauswahl. Niedrigere Temperaturen eignen sich gut für Prompts, die eine weniger offene oder kreative Antwort erfordern, während höhere Temperaturen zu vielfältigeren oder kreativeren Ergebnissen führen können. Eine Temperatur von 0 bedeutet, dass immer die Tokens mit der höchsten Wahrscheinlichkeit ausgewählt werden. In diesem Fall sind die Antworten auf einen bestimmten Prompt größtenteils deterministisch, aber eine gewisse Variation ist dennoch möglich. Wenn das Modell eine zu allgemeine oder zu kurze Antwort zurückgibt, oder wenn das Modell eine Fallback-Antwort ausgibt, versuchen Sie, die Temperatur zu erhöhen. Bereich für gemini-2.0-flash-lite: 0.0 - 2.0 (Standardeinstellung: 1.0)

- Bereich für `gemini-2.0-flash`: `0.0` - `2.0` (Standardeinstellung: `1.0`)

Weitere Informationen finden Sie unter [Parameter für die Inhaltsgenerierung](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/content-generation-parameters?hl=de#temperature) (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/content-generation-parameters?hl=de#temperature>).

topP	Optional: <code>float</code> Falls angegeben, wird Nucleus-Sampling verwendet. Der Wert <code>Top-P</code> (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/content-generation-parameters?hl=de#top-p) ändert, wie das Modell Tokens für die Ausgabe auswählt. Die Tokens werden von den wahrscheinlichsten (siehe „Top-K“) bis zu den unwahrscheinlichsten Werten ausgewählt, bis die Summe ihrer Wahrscheinlichkeiten dem „Top-P“-Wert entspricht. Beispiel: Wenn die Tokens A, B und C eine Wahrscheinlichkeit von 0,3, 0,2 und 0,1 haben und der „Top-P“-Wert <code>0.5</code> ist, wählt das Modell anhand der Temperatur entweder A oder B als das nächste Token und schließt C als Kandidaten aus. Geben Sie einen niedrigeren Wert für weniger zufällige Antworten und einen höheren Wert für zufälligere Antworten an. • Bereich: <code>0.0</code> - <code>1.0</code> • Standardeinstellung für <code>gemini-2.0-flash-lite</code>: <code>0.95</code> • Standardeinstellung für <code>gemini-2.0-flash</code>: <code>0.95</code>
candidateCount	Optional: <code>int</code> Die Anzahl der zurückzugebenden Antwortvarianten. Für jede Anfrage werden Ihnen die Ausgabetokens aller Kandidaten in Rechnung gestellt, aber nur einmal für die Eingabetokens. Die Angabe mehrerer Kandidaten ist eine Funktion in der Vorabversion, die mit <code>generateContent</code> funktioniert (<code>streamGenerateContent</code> wird nicht unterstützt). Die folgenden Modelle werden unterstützt: • <code>gemini-2.0-flash-lite</code>: <code>1–8</code>, Standard: <code>1</code> • <code>gemini-2.0-flash</code>: <code>1–8</code>, Standard: <code>1</code>
maxOutputTokens	Optional: <code>int</code> Maximale Anzahl an Tokens, die in der Antwort generiert werden können. Ein Token besteht aus etwa vier Zeichen. 100 Tokens entsprechen etwa 60–80 Wörtern. Geben Sie kürzere Werte für kürzere Antworten und höhere Werte für längere Antworten an. Weitere Informationen finden Sie unter Parameter für die Inhaltsgenerierung (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/content-generation-parameters?hl=de#max-output-tokens). .
stopSequences	Optional: <code>List[string]</code> Gibt eine Liste an Strings an, die das Modell anweist, Text nicht mehr zu generieren, wenn einer der Strings in der Antwort gefunden wird. Kommt ein String mehrmals in der Antwort vor, so wird die Antwort an der Stelle abgeschnitten, an der er erfasst wurde. Bei Strings wird zwischen Groß- und Kleinschreibung unterschieden. Wenn zum Beispiel folgende Antwort zurückgegeben wird und <code>stopSequences</code> nicht angegeben ist: <pre>public static string reverse(string myString)</pre> Dann lautet zurückgegebene Antwort mit <code>stopSequences</code> auf <code>["Str", "reverse"]</code> gesetzt: <pre>public static string</pre> Die Liste darf maximal fünf Elemente enthalten. Weitere Informationen finden Sie unter Parameter für die Inhaltsgenerierung (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/content-generation-parameters?hl=de#stop-sequences). .
presencePenalty	Optional: <code>float</code> Positive Strafen. Positive Werte nehmen Abzüge bei Tokens vor, die wiederholt im generierten Text angezeigt werden, wodurch die Wahrscheinlichkeit wiederholter Inhalte verringert wird. Der Maximalwert für <code>presencePenalty</code> geht bis, aber nicht einschließlich <code>2.0</code>. Der Mindestwert ist <code>-2.0</code>.
frequencyPenalty	Optional: <code>float</code>

Positive Werte nehmen Abzüge bei Tokens vor, die wiederholt im generierten Text angezeigt werden, wodurch die Wahrscheinlichkeit wiederholter Inhalte verringert wird.

Dieser Maximalwert für **frequencyPenalty** geht bis, aber nicht einschließlich **2.0**. Der Mindestwert ist **-2.0**.

responseMimeType

Optional: **string** (enum)

MIME-Typ der Ausgabeantwort des generierten Kandidatentextes.

Die folgenden MIME-Typen werden unterstützt:

- **application/json**: JSON-Antwort in den Kandidaten.
- **text/plain** (Standard): Nur-Text-Ausgabe.
- **text/x.enum**: Geben Sie für Klassifizierungsaufgaben einen Enum-Wert aus, wie im Antwortschema definiert.

Geben Sie den entsprechenden Antworttyp an, um unerwünschtes Verhalten zu vermeiden. Wenn Sie beispielsweise eine Antwort im JSON-Format benötigen, geben Sie **application/json** und nicht **text/plain** an.

text/plain wird nicht für die Verwendung mit **responseSchema** unterstützt.

responseSchema

Optional: Schema
(<https://docs.cloud.google.com/vertex-ai/docs/reference/rest/v1/projects.locations.cachedContents?hl=de#Schema>)

Das Schema, dem der generierte Kandidatentext entsprechen muss. Weitere Informationen finden Sie unter Ausgabe steuern (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/control-generated-output?hl=de>).

Wenn Sie diesen Parameter verwenden möchten, müssen Sie für den Parameter **responseMimeType** einen unterstützten MIME-Typ angeben, der nicht **text/plain** ist.

seed

Optional: **int**

Wenn die Seed-Daten auf einen bestimmten Wert festgelegt sind, versucht das Modell, für wiederholte Anfragen dieselbe Antwort bereitzustellen. Die deterministische Ausgabe wird nicht zwangsläufig erfüllt. Wenn Sie die Modell- oder Parametereinstellungen ändern, z. B. die Temperatur, kann dies außerdem zu Abweichungen in der Antwort führen, selbst wenn Sie denselben Seed-Wert verwenden. Standardmäßig wird ein zufälliger Startwert verwendet.

responseLogprobs

Optional: **boolean**

Wenn „true“, werden die Logwahrscheinlichkeiten der Tokens zurückgegeben, die vom Modell in jedem Schritt ausgewählt wurden. Standardmäßig ist dieser Parameter auf **false** eingestellt.

logprobs

Optional: **int**

Gibt die Log-Wahrscheinlichkeiten der Top-Kandidaten-Tokens bei jedem Generierungsschritt zurück. Das vom Modell ausgewählte Token ist möglicherweise nicht mit dem Token des Top-Kandidaten in jedem Schritt identisch. Geben Sie die Anzahl der Kandidaten an, die zurückgegeben werden sollen, indem Sie eine Ganzzahl im Bereich von **1** bis **20** angeben.

Sie müssen **responseLogprobs** (**#responseLogprobs**) aktivieren, um diesen Parameter verwenden zu können.

audioTimestamp

Optional: **boolean**

Verfügbar für die folgenden Modelle:

- Gemini 2.0 Flash-Lite
- Gemini 2.0 Flash

Ermöglicht das Erkennen von Zeitstempeln für reine Audiodateien.

Dies ist eine Funktion in der Vorabversion.

thinkingConfig

Optional: **object**

Konfiguration für den Denkprozess (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/thinking?hl=de>) des Modells für Gemini 2.5-Modelle.

Das **thinkingConfig**-Objekt enthält das folgende Feld:

- **thinkingBudget: integer**. Standardmäßig steuert das Modell automatisch, wie viel es sich bis zu maximal **8,192** Tokens ausdenkt.

Antworttext

```
{
  "candidates": [
    {
```

```
"content": {
  "parts": [
    {
      "text": string
    }
  ]
},
"finishReason": enum (FinishReason),
"safetyRatings": [
  {
    "category": enum (HarmCategory),
    "probability": enum (HarmProbability),
    "blocked": boolean
  }
],
"citationMetadata": {
  "citations": [
    {
      "startIndex": integer,
      "endIndex": integer,
      "uri": string,
      "title": string,
      "license": string,
      "publicationDate": {
        "year": integer,
        "month": integer,
        "day": integer
      }
    }
  ]
},
"avgLogprobs": double,
"logprobsResult": {
  "topCandidates": [
    {
      "candidates": [
        {
          "token": string,
          "logProbability": float
        }
      ]
    }
  ],
  "chosenCandidates": [
    {
      "token": string,
      "logProbability": float
    }
  ]
}
},
"usageMetadata": {
  "promptTokenCount": integer,
  "candidatesTokenCount": integer,
  "totalTokenCount": integer
},
"modelVersion": string
}
```

Antwortelement	Beschreibung
modelVersion	Das für die Generierung verwendete Modell und die Version. Beispiel: gemini-2.0-flash-lite-001 .
text	Der generierte Text.
finishReason	Der Grund, warum das Modell keine Tokens mehr generiert. Wenn leer, wird das Modell weiterhin die Tokens generieren. Da die Antwort die Eingabeaufforderung für Kontext verwendet, kann das Verhalten des Modells nicht mehr geändert werden, um Tokens zu generieren. FINISH_REASON_STOP: Natürlicher Stopppunkt des Modells oder angegebene Stoppsequenz. FINISH_REASON_MAX_TOKENS: Die in der Anfrage angegebene maximale Anzahl von Tokens wurde erreicht.

	FINISH_REASON_SAFETY: Die Tokengenerierung wurde gestoppt, da die Antwort aus Sicherheitsgründen gemeldet wurde. Candidate.content ist leer, wenn Inhaltsfilter die Ausgabe blockieren. FINISH_REASON_RECITATION: Die Tokengenerierung wurde gestoppt, da die Antwort wegen nicht autorisierter Zitate gekennzeichnet wurde. FINISH_REASON_BLOCKLIST: Die Tokengenerierung wurde gestoppt, da die Antwort gesperrte Begriffe enthält. FINISH_REASON_PROHIBITED_CONTENT: Die Tokengenerierung wurde gestoppt, da die Antwort wegen verbotener Inhalte wie Darstellungen des sexuellen Missbrauchs von Kindern gemeldet wurde. FINISH_REASON_SPII: Die Tokengenerierung wurde gestoppt, da die Antwort wegen vertraulicher personenidentifizierbarer Informationen gekennzeichnet wurde. FINISH_REASON_MALFORMED_FUNCTION_CALL: Kandidaten wurden aufgrund eines fehlerhaften und nicht parsierbaren Funktionsaufrufs blockiert. FINISH_REASON_OTHER: Alle anderen Gründe, die das Token gestoppt haben FINISH_REASON_UNSPECIFIED: Der Grund für Fertig ist nicht angegeben.
category	Die Sicherheitskategorie, für die ein Schwellenwert konfiguriert wird. Unter anderem sind folgende Werte zulässig: Zum Maximieren von Sicherheitskategorien klicken - HARM_CATEGORY_SEXUALLY_EXPLICIT - HARM_CATEGORY_HATE_SPEECH - HARM_CATEGORY_HARASSMENT - HARM_CATEGORY_DANGEROUS_CONTENT
probability	Die Wahrscheinlichkeitsstufen für Schäden in den Inhalten. - HARM_PROBABILITY_UNSPECIFIED - NEGLIGIBLE - LOW - MEDIUM - HIGH
blocked	Ein boolesches Flag, das mit einem Sicherheitsattribut verknüpft ist, das angibt, ob die Ein- oder Ausgabe des Modells blockiert wurde.
startIndex	Eine Ganzzahl, die angibt, wo eine Zitation im content beginnt. Der Wert für startIndex wird in Byte angegeben und aus der in UTF-8 codierten Antwort berechnet.
endIndex	Eine Ganzzahl, die angibt, wo eine Zitation in content endet. Der Wert für endIndex wird in Byte angegeben und aus der in UTF-8 codierten Antwort berechnet.
url	Die URL einer Zitationsquelle. Beispiele für eine URL-Quelle sind beispielsweise eine Nachrichtenwebsite oder ein GitHub-Repository.
title	Der Titel einer Zitationsquelle. Beispiele für Quelltitel sind der eines Nachrichtenartikels oder eines Buches.
license	Die mit einer Zitation verknüpfte Lizenz.
publicationDate	Das Datum, an dem ein Zitat veröffentlicht wurde. Die gültigen Formate sind YYYY, YYYY-MM und YYYY-MM-DD.
avgLogprobs	Durchschnittliche Log-Wahrscheinlichkeit des Kandidaten.
logprobsResult	Gibt die Top-Kandidaten-Tokens (topCandidates) und die tatsächlich ausgewählten Tokens (chosenCandidates) bei jedem Schritt zurück.
token	Modelle für generative KI zerlegen Textdaten zur Verarbeitung in Tokens, die Zeichen, Wörter oder Wortgruppen sein können.
logProbability	Ein Log-Wahrscheinlichkeitswert, der das Konfidenzniveau des Modells für ein bestimmtes Token angibt.
promptTokenCount	Anzahl der Tokens in der Anfrage.
candidatesTokenCount	Anzahl der Tokens in den Antworten.
totalTokenCount	Anzahl der Tokens in der Anfrage und den Antworten.

Beispiele

Textgenerierung

Generiert eine Textantwort aus einer Texteingabe.

```
from google import genai
from google.genai.types import HttpOptions

client = genai.Client(http_options=HttpOptions(api_version="v1"))
response = client.models.generate_content(
    model="gemini-2.5-flash",
    contents="How does AI work?",
)
print(response.text)
# Example response:
# Okay, let's break down how AI works. It's a broad field, so I'll focus on the ...
#
# Here's a simplified overview:
# ...
```

Multimodale Prompts verwenden

Generieren Sie eine Textantwort aus einer multimodalen Eingabe wie Text und einem Bild.

```
from google import genai
from google.genai.types import HttpOptions, Part

client = genai.Client(http_options=HttpOptions(api_version="v1"))
response = client.models.generate_content(
    model="gemini-2.5-flash",
    contents=[
        "What is shown in this image?",
        Part.from_uri(
            file_uri="gs://cloud-samples-data/generative-ai/image/scones.jpg",
            mime_type="image/jpeg",
        ),
    ],
)
print(response.text)
# Example response:
# The image shows a flat lay of blueberry scones arranged on parchment paper. There are ...
```

Streaming-Textantwort

Streamingmodellantwort aus einer Texteingabe generieren

```
from google import genai
from google.genai.types import HttpOptions

client = genai.Client(http_options=HttpOptions(api_version="v1"))

for chunk in client.models.generate_content_stream(
    model="gemini-2.5-flash",
    contents="Why is the sky blue?",
):
    print(chunk.text, end="")
# Example response:
# The
# sky appears blue due to a phenomenon called **Rayleigh scattering**. Here's
# a breakdown of why:
# ...
```

Modellversionen

Wenn Sie die automatisch aktualisierte Version

(<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/model-versioning?hl=de#auto-updated-version>) verwenden möchten, geben Sie den Modellnamen ohne die nachgestellte Versionsnummer an, z. B. `gemini-2.0-flash` anstelle von `gemini-2.0-flash-001`.

Weitere Informationen finden Sie unter Modellversionen und Lebenszyklus

(<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/learn/model-versioning?hl=de#gemini-model-versions>).

Nächste Schritte

- Weitere Informationen zur Gemini API in Vertex AI (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/gemini?hl=de>)
- Weitere Informationen zu Funktionsaufrufen (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de>)
- Weitere Informationen zum Fundieren von Antworten für Gemini-Modelle
(<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/ground-gemini?hl=de>)

Sofern nicht anders angegeben, sind die Inhalte dieser Seite unter der Creative Commons Attribution 4.0 License (<https://creativecommons.org/licenses/by/4.0/>) und Codebeispiele unter der Apache 2.0 License (<https://www.apache.org/licenses/LICENSE-2.0>) lizenziert. Weitere Informationen finden Sie in den Websiterichtlinien von Google Developers (<https://developers.google.com/site-policies?hl=de>). Java ist eine eingetragene Marke von Oracle und/oder seinen Partnern.

Zuletzt aktualisiert: 2025-10-19 (UTC).