

Referenz zu Funktionsaufrufen

Durch den Funktionsaufruf kann das LLM relevantere und kontextbezogenere Antworten liefern.

Mit der Function Calling API können Sie einem generativen KI-Modell benutzerdefinierte Funktionen zur Verfügung stellen. Das Modell ruft diese Funktionen nicht direkt auf, sondern generiert eine strukturierte Datenausgabe, in der der Funktionsname und die vorgeschlagenen Argumente angegeben sind.

Mit dieser Ausgabe können externe APIs oder Informationssysteme wie Datenbanken, Customer-Relationship-Management-Systeme und Dokument-Repositories aufgerufen werden. Die resultierende API-Ausgabe kann vom LLM verwendet werden, um die Qualität der Antwort zu verbessern.

Weitere konzeptionelle Dokumentationen zum Funktionsaufruf finden Sie unter [Funktionsaufrufe](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de).

Unterstützte Modelle

- [Gemini 2.5 Flash](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=de) (Vorschau)
- [Gemini 2.5 Flash-Lite](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=de) (Vorschau)
- [Gemini 2.5 Flash-Lite](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-lite?hl=de)
- [Gemini 2.5 Flash mit nativer Audio-Live-API](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-live-api?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash-live-api?hl=de) (Vorabversion)
- [Gemini 2.0 Flash mit Live API](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash?hl=de#live-api) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash?hl=de#live-api) (Vorschau)
- [Gemini 2.5 Pro](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-pro?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-pro?hl=de)
- [Gemini 2.5 Flash](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash?hl=de)
- [Gemini 2.0 Flash](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash?hl=de)
- [Gemini 2.0 Flash-Lite](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash-lite?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-0-flash-lite?hl=de)

Beschränkungen:

- Die maximale Anzahl von Funktionsdeklarationen, die mit der Anfrage bereitgestellt werden können, beträgt 128.

Beispielsyntax

Syntax zum Senden einer API-Anfrage für einen Funktionsaufruf.

```
curl
(#curl)

curl -X POST \
  -H "Authorization: Bearer $(gcloud auth print-access-token)" \
  -H "Content-Type: application/json" \

https://${LOCATION}-aiplatform.googleapis.com/v1/projects/${PROJECT_ID}/locations/${LOCATION}/publishers/google/models/${MODEL_NAME}:generateContent \
-d '{
  "contents": [{
    ...
  }],
  "tools": [{
    "function_declarations": [
      {
        ...
      }
    ]
  }
}
```

```
}']
    }]
}'
```

Parameterliste

Einzelheiten zur Implementierung finden Sie in den [Beispielen](#) (#examples).

FunctionDeclaration

Definiert eine Funktion, für die das Modell auf Grundlage der [OpenAPI 3.0-Spezifikationen](https://spec.openapis.org/oas/v3.0.3) (https://spec.openapis.org/oas/v3.0.3) JSON-Eingaben generieren kann.

Parameter	
name	string Der Name der aufzurufenden Funktion. Muss mit einem Buchstaben oder Unterstrich beginnen. Muss a–z, A–Z, 0–9 sein oder Unterstriche, Punkte oder Bindestriche enthalten. Die maximale Länge beträgt 64.
description	Optional: string Die Beschreibung und der Zweck der Funktion. Anhand dieser Informationen entscheidet das Modell, wie und ob die Funktion aufgerufen werden soll. Für optimale Ergebnisse empfehlen wir, eine Beschreibung anzugeben.
parameters	Optional: Schema Beschreibt die Parameter der Funktion im OpenAPI-JSON-Schemaobjektformat: OpenAPI 3.0-Spezifikation (https://spec.openapis.org/oas/v3.0.3).
response	Optional: Schema Beschreibt die Ausgabe der Funktion im OpenAPI-JSON-Schemaobjektformat: OpenAPI 3.0-Spezifikation (https://spec.openapis.org/oas/v3.0.3).

Weitere Informationen finden Sie unter [Funktionsaufrufe](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de).

Schema

Definiert das Format der Ein- und Ausgabedaten in einem Funktionsaufruf basierend auf der [OpenAPI 3.0-Schemaspezifikation](https://spec.openapis.org/oas/v3.0.3#schema) (https://spec.openapis.org/oas/v3.0.3#schema).

Parameter	
Typ	string Enum. Der Typ der Daten. Muss einer der folgenden sein: • STRING • INTEGER • BOOLEAN • NUMBER • ARRAY • OBJECT
description	Optional: string Beschreibung der Daten.
enum	Optional: string[] Mögliche Werte des Elements des einfachen Typs im enum-Format.
items	Optional: Schema[] Schema der Elemente von Type.ARRAY

properties	Optional: Schema
	Schema der Attribute von <code>Type.OBJECT</code>
required	Optional: <code>string[]</code>
	Erforderliche Properties von <code>Type.OBJECT</code> .
nullable	Optional: <code>bool</code>
	Gibt an, ob der Wert <code>null</code> sein darf.

FunctionCallingConfig

Die `FunctionCallingConfig` steuert das Verhalten des Modells und bestimmt, welche Art von Funktion aufgerufen wird.

Parameter

mode	Optional: <code>enum/string[]</code>
	• AUTO: Standardmäßiges Modellverhalten. Das Modell kann Vorhersagen entweder in Form eines Funktionsaufrufs oder in Form einer Antwort in natürlicher Sprache treffen. Das Modell entscheidet anhand des Kontexts, welche Form verwendet werden soll.
	• NONE: Das Modell gibt keine Vorhersagen in Form von Funktionsaufrufen aus.
	• ANY: Das Modell ist darauf beschränkt, immer einen Funktionsaufruf vorherzusagen. Wenn <code>allowed_function_names</code> nicht angegeben ist, wählt das Modell aus allen verfügbaren Funktionsdeklarationen aus. Wenn <code>allowed_function_names</code> angegeben wird, wählt das Modell aus der Menge der zulässigen Funktionen aus.
allowed_function_names	Optional: <code>string[]</code>
	Namen der aufzurufenden Funktionen. Nur festgelegt, wenn der <code>mode ANY</code> ist. Funktionsnamen sollten mit <code>[FunctionDeclaration.name]</code> übereinstimmen. Wenn der Modus auf <code>ANY</code> festgelegt ist, sagt das Modell einen Funktionsaufruf aus der Menge der bereitgestellten Funktionsnamen voraus.

functionCall

Ein vorhergesagter `functionCall`, der vom Modell zurückgegeben wird und einen String enthält, der `functionDeclaration.name` und ein strukturiertes JSON-Objekt enthält, das die Parameter und ihre Werte enthält.

Parameter

name	<code>string</code>
	Der Name der aufzurufenden Funktion.
args	<code>Struct</code>
	Die Funktionsparameter und -werte im JSON-Objektformat.
	Weitere Informationen zu Parametern finden Sie unter Funktionsaufrufe (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/function-calling?hl=de).

functionResponse

Die resultierende Ausgabe von einem `FunctionCall`, das einen String mit der `FunctionDeclaration.name` enthält. Enthält auch ein strukturiertes JSON-Objekt mit der Ausgabe der Funktion, das als Kontext für das Modell verwendet wird. Dieser sollte das Ergebnis einer `FunctionCall` enthalten, die auf der Grundlage der Modellvorhersage erstellt wurde.

Parameter

name	<code>string</code>
	Der Name der aufzurufenden Funktion.
response	<code>Struct</code>
	Die Funktionsantwort im JSON-Objektformat.

Beispiele

Funktionsdeklaration senden

Das folgende Beispiel zeigt, wie Sie eine Abfrage und eine Funktionsdeklaration an das Modell senden.

RESTGen AI SDK für Python...
(#rest)

Node.js (#node.js)Java (#java)Go (#go)REST (OpenAI) (#rest-openai)Python (OpenAI)...

Ersetzen Sie diese Werte in den folgenden Anfragedaten:

- **PROJECT_ID** : Ihre Projekt-ID (<https://docs.cloud.google.com/resource-manager/docs/creating-managing-projects?hl=de#identifiers>).
- **MODEL_ID** : Die ID des Modells, das verarbeitet wird.
- **ROLE** : Die Identität der Entität (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/model-reference/inference?hl=de#content>), die die Nachricht erstellt.
- **TEXT** : Der Prompt, der an das Modell gesendet werden soll.
- **NAME** : Der Name der aufzurufenden Funktion.
- **DESCRIPTION** : Beschreibung und Zweck der Funktion.
- Informationen zu anderen Feldern finden Sie in der Tabelle Parameterliste (#parameter-list).

HTTP-Methode und URL:

POST https://aiplatform.googleapis.com/v1/projects/PROJECT_ID/locations/global/publishers/google/models/MODEL_ID

JSON-Text der Anfrage:

```
{
  "contents": [{
    "role": "ROLE",
    "parts": [{
      "text": "TEXT"
    }]
  }],
  "tools": [{
    "function_declarations": [
      {
        "name": "NAME",
        "description": "DESCRIPTION",
        "parameters": {
          "type": "TYPE",
          "properties": {
            "location": {
              "type": "TYPE",
              "description": "DESCRIPTION"
            }
          }
        },
        "required": [
          "location"
        ]
      }
    ]
  }
]
```

Wenn Sie die Anfrage senden möchten, wählen Sie eine der folgenden Optionen aus:

curlPowerShell (#powershell)
(#curl)

★ **Hinweis:** Der folgende Befehl setzt voraus, dass Sie sich mit Ihrem Nutzerkonto bei der **gcloud** CLI angemeldet haben, indem Sie **gcloud init** (<https://docs.cloud.google.com/sdk/gcloud/reference/init?hl=de>) oder **gcloud auth login** (<https://docs.cloud.google.com/sdk/gcloud/reference/auth/login?hl=de>) ausgeführt oder die **Cloud Shell** (<https://docs.cloud.google.com/shell/docs?hl=de>) genutzt haben, die Sie automatisch bei der **gcloud** CLI anmeldet. Zum Prüfen des derzeit aktiven Kontos führen Sie **gcloud auth list** (<https://docs.cloud.google.com/sdk/gcloud/reference/auth/list?hl=de>) aus.

Speichern Sie den Anfragetext in einer Datei mit dem Namen `request.json` und führen Sie den folgenden Befehl aus:

```
curl -X POST \
-H "Authorization: Bearer $(gcloud auth print-access-token)" \
-H "Content-Type: application/json; charset=utf-8" \
-d @request.json \
"https://aiplatform.googleapis.com/v1/projects/PROJECT_ID /locations/global/publishers/google/models/MO
```

Beispiel: cURL-Befehls

```
PROJECT_ID=myproject
LOCATION=us-central1
MODEL_ID=gemini-2.5-flash
```

```
curl -X POST \
-H "Authorization: Bearer $(gcloud auth print-access-token)" \
-H "Content-Type: application/json" \
https://${LOCATION}-aiplatform.googleapis.com/v1/projects/${PROJECT_ID}/locations/${LOCATION}/publishers/google/mc
-d '{
  "contents": [{
    "role": "user",
    "parts": [{
      "text": "What is the weather in Boston?"
    }]
  }],
  "tools": [{
    "functionDeclarations": [
      {
        "name": "get_current_weather",
        "description": "Get the current weather in a given location",
        "parameters": {
          "type": "object",
          "properties": {
            "location": {
              "type": "string",
              "description": "The city and state, e.g. San Francisco, CA or a zip code e.g. 95616"
            }
          },
          "required": [
            "location"
          ]
        }
      }
    ]
  }
}]
}'
```

Funktionsdeklaration mit FunctionCallingConfig senden

Das folgende Beispiel zeigt, wie eine `FunctionCallingConfig` an das Modell übergeben wird.

Die `functionCallingConfig` sorgt dafür, dass die Modellausgabe immer ein bestimmter Funktionsaufruf ist. Zum Konfigurieren:

- Legen Sie den Funktionsaufruf `mode` auf `ANY` fest.

- Geben Sie die Funktionsnamen an, die Sie in `allowed_function_names` verwenden möchten. Wenn `allowed_function_names` leer ist, kann eine der bereitgestellten Funktionen zurückgegeben werden.

REST (#rest)Gen AI SDK für Python...Node.js (#node.js)Go (#go)REST (OpenAI)Python (OpenAI)...(#rest-openai)

Sie können die Function Calling API mit der OpenAI-Bibliothek aufrufen. Weitere Informationen finden Sie unter [Vertex AI-Modelle mithilfe der OpenAI-Bibliothek aufrufen](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/call-vertex-using-openai-library?hl=de) (<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/call-vertex-using-openai-library?hl=de>).

Ersetzen Sie diese Werte in den folgenden Anfragedaten:

- `PROJECT_ID` : .
- `MODEL_ID` : Die ID des Modells, das verarbeitet wird.

HTTP-Methode und URL:

POST https://aiplatform.googleapis.com/v1beta1/projects/PROJECT_ID/locations/global/endpoints/openapi/chat/comple

JSON-Text der Anfrage:

```
{
  "model": "google/MODEL_ID ",
  "messages": [
    {
      "role": "user",
      "content": "What is the weather in Boston?"
    }
  ],
  "tools": [
    {
      "type": "function",
      "function": {
        "name": "get_current_weather",
        "description": "Get the current weather in a given location",
        "parameters": {
          "type": "OBJECT",
          "properties": {
            "location": {
              "type": "string",
              "description": "The city and state, e.g. San Francisco, CA or a zip code e.g. 95616"
            }
          },
          "required": ["location"]
        }
      }
    }
  ],
  "tool_choice": "auto"
}
```

Wenn Sie die Anfrage senden möchten, wählen Sie eine der folgenden Optionen aus:

curlPowerShell (#powershell)(#curl)

★ **Hinweis:** Der folgende Befehl setzt voraus, dass Sie sich mit Ihrem Nutzerkonto bei der `gcloud` CLI angemeldet haben, indem Sie `gcloud init` (<https://docs.cloud.google.com/sdk/gcloud/reference/init?hl=de>) oder `gcloud auth login` (<https://docs.cloud.google.com/sdk/gcloud/reference/auth/login?hl=de>) ausgeführt oder die [Cloud Shell](https://docs.cloud.google.com/shell/docs?hl=de) (<https://docs.cloud.google.com/shell/docs?hl=de>) genutzt haben, die Sie automatisch bei der `gcloud` CLI anmeldet. Zum Prüfen des derzeit aktiven Kontos führen Sie `gcloud auth list` (<https://docs.cloud.google.com/sdk/gcloud/reference/auth/list?hl=de>) aus.

Speichern Sie den Anfragetext in einer Datei mit dem Namen `request.json` und führen Sie den folgenden Befehl aus:


```
curl -X POST \
  -H "Authorization: Bearer $(gcloud auth print-access-token)" \
  -H "Content-Type: application/json; charset=utf-8" \
  -d @request.json \
  "https://aiplatform.googleapis.com/v1beta1/projects/PROJECT_ID /locations/global/endpoints/openapi/chat
```

Nächste Schritte

Eine ausführliche Dokumentation finden Sie hier:

- [Funktionsaufrufe](https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de) (https://docs.cloud.google.com/vertex-ai/generative-ai/docs/multimodal/function-calling?hl=de)

Sofern nicht anders angegeben, sind die Inhalte dieser Seite unter der [Creative Commons Attribution 4.0 License](https://creativecommons.org/licenses/by/4.0/) (https://creativecommons.org/licenses/by/4.0/) und Codebeispiele unter der [Apache 2.0 License](https://www.apache.org/licenses/LICENSE-2.0) (https://www.apache.org/licenses/LICENSE-2.0) lizenziert. Weitere Informationen finden Sie in den [Websiterichtlinien von Google Developers](https://developers.google.com/site-policies?hl=de) (https://developers.google.com/site-policies?hl=de). Java ist eine eingetragene Marke von Oracle und/oder seinen Partnern.

Zuletzt aktualisiert: 2025-10-19 (UTC).